医院 AI 辅助系统本地部署方案（推广版）

> 编制日期：2026 年 10 月 31 日
> 适用对象：1000 张床位及以下的二级/县级医院
> 核心特点：**单院投入 3–5 万元起，数据不出医院，可先试后用**

一、方案概览

本方案在两台普通服务器的成本内，为医院部署一套**完全本地运行**的 AI 辅助系统，覆盖诊断分析、诊疗计划、病历文书三大场景。

项目	内容
部署位置	医院内网机房（数据不出院）
起步投入	**3.24 万元**（一台单卡服务器）
覆盖床位	1000 张以内
起步形态	1 台服务器，可先试用 3 个月
扩展方式	按需加服务器，不换整机

与"云服务"的根本区别：所有病历数据、AI 推理都在院内完成，不经过任何外部网络。

二、两个可选配置

配置一：单卡版（推荐起步）

项目	规格	价格
计算卡	AMD R9700 32 GB 专业卡	16,099 元
处理器	AMD Ryzen 9 9950X（16 核）	4,500 元
主板	X870E 工作站主板	3,000 元
内存	64 GB DDR5	6,000 元
电源	850 W 金牌（专业卡原生供电）	900 元
机箱 / 硬盘 / 散热	中塔 / 2 TB 固态 / 风冷	1,900 元

项目	规格	价格
整机合计	含上述全部部件	**32,399 元**

能力：**同时支持 8 路并发**，**每天可处理约 1,300 名住院患者**。

> 换算：约 4,000 份文书 / 天。按 1,000 张床位计算，可覆盖全院在院患者每日一次，余量约 30%。

配置二：双卡版（1000 床以上，或对速度要求高）

在单卡版基础上增加一张计算卡与更大电源：

项目	与单卡版的差异	追加	合计
计算卡	再加 1 张 R9700 32 GB	+16,099 元	
电源 / 机箱	850 W → 1200 W，中塔 → 全塔	+800 元	
整机合计			**49,998 元**

能力：**同时支持 8 路并发**（与单卡版相同），**每天可处理约 2,600 名住院患者**（约为单卡版的两倍）。

> 换算：约 7,800 份文书 / 天。按 2,000 张床位计算，可覆盖全院在院患者每日一次，余量约 30%。

> **为什么双卡能翻倍**：单卡时 AI 模型有部分权重放不进显存，需要临时从内存调取，拖慢处理速度；两张卡后全部权重常驻显存，不再等待，同样时间能处理两倍的病人。

三、系统能做什么

项目	单卡版	双卡版
每天可处理的住院患者	**约 1,300 人**	**约 2,600 人**
每天可生成的文书数	约 4,000 份	约 7,800 份
同时并发路数	**8 路**	**8 路**
适用床位	1000 张以内	1000–2000 张

通俗理解：单卡版相当于"一晚上能把全院 1000 名住院患者的文书各跑一遍"；双卡版相当于"一晚上覆盖 2000 张床位"。

使用方式：白天医生点击即用（**8 路并发**）；夜间系统自动批量生成，次日上班前完成。医生 08:00 上班时，全部结果已就绪。

四、必须明确的边界（重要）

以下四点请在决策前知悉，我们不做隐瞒：

1. AI 产出是"初稿"，不是"结论"

本地模型的诊断分析质量评分约 **3.56 / 5**，而同规模云端模型为 4.18 / 5。

这意味着：AI 生成的诊断分析、诊疗计划**必须由医生逐条复核后才能使用**，不能直接落库、不能自动进入病历。

系统的定位是"减少医生打字时间"，不是"替代医生判断"。

2. 没有备份机

单卡版只有一台服务器。如果这台机器故障（电源、主板、硬盘），**AI 服务会中断 4–24 小时**，期间医生需手动书写文书。

- 服务器三年故障率约 2–5%
- 计算卡单卡故障率约 1–2% / 年
- 单卡版**坏一张卡即全停**（双卡版可降级继续跑）

如医院要求不间断服务，需要增加一台备用机（+3.24 万元）。

3. 不能升级到更高配置

为压低成本，本方案采用消费级平台，**计算卡数量锁死**。若未来业务量增长（如增加 DRG、MCC 分析），只能整机更换，无法在原机加卡。

如需保留升级能力，应选择标准版（9.25 万元起，可扩至 4 卡）。

4. 质保为消费级

3 年送修，不是 7×24 小时原厂上门。如医院要求原厂响应，需单独加保。

五、为什么能做到 3 万元级

同类方案动辄数十万元，本方案压缩成本的三个来源：

做法	节省
不购买"可扩展 4 卡"的工作站平台	约 3.5 万元
采用消费级处理器与主板（性能足够）	约 1.5 万元
内存按实际需要配置 64 GB（非 128 GB）	约 0.6–1.5 万元

做法	节省
利用医院现有内网机房、UPS、网络	省去全部配套采购

代价是放弃了扩展性和冗余，这正是第四节所述边界的由来。

六、投入与产出

指标	单卡版	双卡版
整机投入	3.24 万元	5.00 万元
每天可处理患者	**约 1,300 人**	**约 2,600 人**
每天可生成文书	约 4,000 份	约 7,800 份
覆盖床位	≤1000 张	1000–2000 张
单床成本	**32 元 / 床**	**25 元 / 床**
年电费（满载 60%）	约 0.25 万元	约 0.45 万元

按 1000 张床位计算，单床一次性投入 32 元——低于一张床位的日常耗材成本。

工时节约（保守估算）：按 1000 张床位、每人每天 1 份文书由 AI 生成初稿（医生复核后使用）、每份节约 10 分钟计算，每天可节约约 **167 小时**医生工时，相当于 20 名医生各 8 小时的工作量。

> 实际节约取决于采用率——并非所有文书都会用 AI 初稿，也并非所有初稿都能直接采纳。这是"理论上限"，供决策参考。

七、落地路径（建议分三步）

第一步：试用（本期投入 3.24 万元）

采购 1 台单卡服务器，部署在院内网机房，选择 1–2 个科室试用 3 个月。

试用期验收指标：

指标	要求
系统可正常加载模型	是
每天可处理患者数	**≥1,200 人**
同时 8 路并发不卡顿	是

指标	要求
连续运行 72 小时无故障	是
医生对文书质量的认可度	≥3.5 / 5 分

第二步：按需扩容（视试用结果）

现状床位	加什么	追加投入	扩容后每天可处理
1000 → 2000 床	加 1 台单卡服务器	3.24 万元	约 2,600 人
2000 → 3000 床	加 1 台双卡服务器	5.00 万元	约 5,200 人
需要不间断服务	加 1 台备用机	3.24 万元	主备自动切换

扩容不需要停机和换机——新服务器接入院内网即可，原有设备继续使用。

第三步：容灾兜底（经费宽松时）

增加 1 台备用机，主服务器故障时自动接管。

八、需要医院配合的事项

事项	说明	责任方
机房机位	1 个标准机位 + 220 V 供电（单卡 0.55 kW，双卡 1.05 kW）	院方信息科
网络接入	院内网千兆接入（实测流量仅 3 KB/s，要求很低）	院方信息科
网段确认	确认服务器所在网段无外网出口（满足"数据不出院"）	院方信息科
医生复核流程	明确 AI 初稿由谁复核、如何签字	医务科
系统集成	与现有 HIS/EMR 对接取数	我方实施

注意：AI 服务器接入的网段若存在外网出口，需在交换机上做一次访问限制（一次性配置，无采购成本）。

九、风险提示（决策前请阅读）

风险	影响	应对
计算卡为 AMD 平台，需验证软件兼容性	若引擎不支持，方案需调整	先行试装 1 张卡验证（1 周内可确认）
AI 文书质量未达医生预期	使用率低	试用期设 3 个月观察，不达标可终止
单点故障导致服务中断	4–24 小时	增配备用机，或接受中断改用手工
计算卡市场价格波动	采购成本上升	合同锁定单价与供货期
本地模型能力有限	无法覆盖复杂病例	复杂病例仍由医生手工处理

十、结论与建议

建议采用"先试后用"的三步走策略：

1. **本期**：投入 3.24 万元，采购 1 台单卡服务器，选 1–2 个科室试用 3 个月
2. **验证**：以试用期 5 项指标为依据，判断是否值得推广
3. **决策**：达标则按床位扩容，不达标则终止，损失控制在 3.24 万元以内

这个方案的价值不在于技术先进性，而在于用最低成本验证"AI 辅助是否真的能减轻医生负担"。 验证成功再追加投入，比一次性采购数十万元的风险小得多。

> **说明**：本文所有价格基于 2026 年 10 月市场行情，实际采购以询价为准。计算卡为 AMD 专业卡，需验证与本系统的兼容性后方可批量采购。