医院 AI 辅助系统本地部署方案

编制日期：2026 年 11 月 4 日（v4.3，按医院规模配置台数）
适用对象：**各级医院**——按床位规模配置服务器台数
核心特点：**单台 3.0 万元起，数据不出医院，按规模加台**

一、方案概览

本方案为医院部署一套**完全本地运行**的 AI 辅助系统，用于诊断分析、诊疗计划、病历文书的初稿生成。

部署形态：单台服务器覆盖约 250 张床位；医院规模更大时，**按台数叠加，不换机型、不停机**。

项目	内容
部署位置	医院内网机房（数据不出院）
单台投入	**3.0 万元**（含安装调试）
单台覆盖	约 250 张床位（按实测速度折算）
扩展方式	按规模加服务器，同型号、同镜像

与"云服务"的根本区别：所有病历数据、AI 推理都在院内完成，不经过任何外部网络。

二、按医院规模配置

医院床位	服务器台数	整机投入	部署说明
250 床	**1 台**	**3.0 万元**	单台覆盖
500 床	2 台	5.7 万元	加 1 台
750 床	3 台	8.4 万元	加 2 台
1000 床	4 台	11.1 万元	加 3 台
1500 床	6 台	16.5 万元	加 5 台
2000 床	8 台	22.2 万元	加 7 台

折算说明：台数按"实测单台速度 × 可用时长 ÷ 医院每日 token 需求"推算，未包含并发争抢、失败重跑等因素。**实际台数以部署后现场压测为准。**

首台 3.0 万元含安装调试、培训与 3 个月技术支持；后续每台 2.7 万元。

三、配置清单（单台）

项目	规格
计算卡	NVIDIA RTX 5070 12 GB
处理器	Intel Core i5-12400（6 核 12 线程）

项目	规格
主板	B660
内存	**64 GB DDR5**
电源	650 W 金牌
存储	2 TB 固态
散热 / 机箱	风冷 / 中塔
交付内容	硬件、系统安装、模型部署、使用培训、3 个月技术支持

> **为什么内存要 64 GB**：AI 模型文件约 62 GB，其中一部分加载到显存，其余需常驻内存。32 GB 内存无法运行本模型。

> **为什么显存 12 GB 够用**：12 GB 显存缓存模型最常访问的部分（实测命中率约 77%），其余从内存读取。在相同模型、相同病例上实测：把显存加大到 32 GB，端到端速度从 102.9 提升到 105.9 token/秒，仅提升 2.9%。

四、实测性能（单台）

以下数据来自本机测试：6 份真实病例、同一脚本、同一测量口径。

项目	数值	数据性质
模型	Qwen3.8-Flash-Next 125B/6B MoE Q2_0	—
模型体积	约 62 GB（磁盘）	实测
端到端生成速度（均值）	**102.9 token/秒**	**实测**
速度范围（6 份病例）	95.0 – 112.2 token/秒	**实测**
显存缓存命中率	约 77%	实测
单份诊断分析 token	14,130	实测（5 例均值）
每患者每日 token（3 类文书）	32,130	实测口径折算

测量口径说明：以上速度是**端到端**（从提交到完成，含输入处理），不是引擎内部的解码速度。后者通常比端到端高 15–30%，不作为对外承诺。

关于单份耗时：同一份文书两次生成，耗时可差 2 倍以上——原因是模型内部推理过程的长短由采样随机性决定，与硬件性能无关。因此耗时以 token 总量衡量，不按"份数"承诺。

五、产能折算（单台）

项目	数值	计算方式
每日可生成 token	**8.15 M**	102.9 token/秒 × 79,200 秒（22 小时窗口）
折算覆盖床位	**约 250 张**	8.15 M ÷ 32,130 token
折算每日文书数	**约 760 份**	250 患者 × 3 类

> **折算说明**：以上是按实测的单请求速度乘以可用时长推算的**上限值**，未包含并发争抢、失败重跑等因素。实际产能以部署后现场压测为准。

六、投入

指标	数值
单台投入（首台）	**3.0 万元**（含安装调试、培训、3 个月技术支持）
单台投入（追加）	**2.7 万元**
单床成本（按 250 床/台）	**120 元 / 床**

七、落地路径（建议分两步）

第一步：试点（1 台，3.0 万元）

采购 1 台服务器，部署在院内网机房，选择 1–2 个科室试用 3 个月。

试点期验收指标（用于判断是否值得推广）：

指标	要求
系统可正常加载模型	是
端到端生成速度	≥95 token/秒
每天可生成的文书数	≥680 份
医生对文书质量的认可度	≥3.5 / 5 分

> 第 2、3 项为验收判据，不是当前承诺值。

第二步：按规模扩展（视试点结果）

现有规模	扩容动作	追加投入
250 → 500 床	加 1 台	2.7 万元
500 → 1000 床	加 2 台	5.4 万元
1000 → 2000 床	加 4 台	10.8 万元

扩容不需要停机和换机——新服务器接入院内网、注册到统一调度即可，原有设备继续使用。

八、需要医院配合的事项

事项	说明	责任方
机房机位	每台占 1 个标准机位 + 220 V 供电	院方信息科
网络接入	院内网千兆接入（实测流量仅 3 KB/s，要求很低）	院方信息科
网段确认	确认服务器所在网段无外网出口（满足"数据不出院"）	院方信息科

事项	说明	责任方
医生复核流程	明确 AI 初稿由谁复核、如何签字	医务科
系统集成	与现有 HIS/EMR 对接取数	我方实施

注意：AI 服务器接入的网段若存在外网出口，需在交换机上做一次访问限制（一次性配置，无采购成本）。

九、结论与建议

建议采用"先试点、后按规模扩展"的两步走策略：

1. **试点**：投入 3.0 万元，采购 1 台服务器，选 1–2 个科室试用 3 个月
2. **决策**：以试点期 4 项指标为依据，达标则按医院规模加台，不达标则终止，损失控制在 3.0 万元以内

这个方案的价值不在于技术先进性，而在于用最低成本验证"AI 辅助是否真的能减轻医生负担"。 验证成功再按规模投入，比一次性采购全部设备的风险小得多。

附：数据来源

项	数据性质	来源
端到端速度 102.9 token/秒	**实测**	本机 6 份真实病例，同一脚本
速度范围 95.0–112.2	**实测**	同上
显存命中率 77%	**实测**	引擎运行指标
显存 12→32 GB 仅提升 2.9%	**实测**	同批病例对照测试
单份诊断分析 14,130 token	**实测**	本机 5 例均值
每日产能 8.15 M token	**折算**	实测速度 × 22 小时
单台覆盖 250 床	**折算**	产能 ÷ 每人 token 需求
各规模台数	**折算**	床位需求 ÷ 单台产能

> **承诺边界**：本文只对"实测"栏的数据负责。"折算"栏为基于实测的推算，实际以现场压测为准。

> **说明**：本方案的所有性能数据均来自本地实测，不是厂商宣传值。报价为整机含安装调试、培训与 3 个月技术支持的价格；硬件价格随市场波动，实际采购以合同为准。

> **AI 生成内容为"初稿"**，须由医生复核后方可使用，系统不替代医生的诊断责任。