医院 AI 辅助系统本地部署方案

编制日期：2026 年 11 月 4 日（v4.1，仅保留有实测依据的数据）
适用对象：250 张床位及以下的二级/县级医院
核心特点：**单院投入 3.0 万元，数据不出医院，可先试后用**

一、方案概览

本方案用一台服务器的预算，为医院部署一套**完全本地运行**的 AI 辅助系统，用于诊断分析、诊疗计划、病历文书的初稿生成。

项目	内容
部署位置	医院内网机房（数据不出院）
起步投入	**3.0 万元**（含安装调试）
覆盖床位	**约 250 张**（按实测速度折算）
起步形态	1 台服务器，可先试用 3 个月
扩展方式	按需加服务器，不换整机、不停机

与"云服务"的根本区别：所有病历数据、AI 推理都在院内完成，不经过任何外部网络。

二、配置清单

单卡服务器（整机报价 3.0 万元，含安装调试）

项目	规格
计算卡	NVIDIA RTX 5070 12 GB
处理器	Intel Core i5-12400（6 核 12 线程）
主板	B660
内存	**64 GB DDR5**
电源	650 W 金牌
存储	2 TB 固态
散热 / 机箱	风冷 / 中塔
交付内容	硬件、系统安装、模型部署、使用培训、3 个月技术支持

为什么内存要 64 GB：AI 模型文件约 62 GB，其中一部分加载到显存，其余需常驻内存。32 GB 内存无法运行本模型。

为什么显存 12 GB 够用：12 GB 显存缓存模型最常访问的部分（实测命中率约 77%），其余从内存读取。**在相同模型、相同病例上实测：把显存加大到 32 GB，端到端速度从 102.9 提升到 105.9 token/秒，仅提升**

> **2.9%。**

三、实测性能

以下数据来自本机测试，6 份真实病例、同一脚本、同一测量口径。

项目	数值	数据性质
模型	Qwen3.8-Flash-Next 125B/6B MoE Q2_0	—
模型体积	约 62 GB（磁盘）	实测
端到端生成速度（均值）	**102.9 token/秒**	**实测**
速度范围（6 份病例）	95.0 – 112.2 token/秒	**实测**
显存缓存命中率	约 77%	实测
单份诊断分析 token	14,130	实测（5 例均值）
每患者每日 token（3 类文书）	32,130	实测口径折算

测量口径说明：以上速度是**端到端**（从提交到完成，含输入处理），不是引擎内部的解码速度。后者通常比端到端高 15–30%，不作为对外承诺。

关于单份耗时：同一份文书两次生成，耗时可差 2 倍以上——原因是模型内部推理过程的长短由采样随机性决定，与硬件性能无关。因此耗时以 token 总量衡量，不按"份数"承诺。

四、产能折算（基于实测速度）

项目	数值	计算方式
每日可生成 token	**8.15 M**	102.9 token/秒 × 79,200 秒（22 小时窗口）
折算覆盖床位	**约 250 张**	8.15 M ÷ 32,130 token
折算每日文书数	**约 760 份**	250 患者 × 3 类

> **折算说明**：以上是按实测的单请求速度乘以可用时长推算的**上限值**，未包含并发争抢、失败重跑等因素。实际产能以部署后现场压测为准。

并发能力：引擎支持 8 路并发（同一时间处理 8 个请求）。8 路并发下的总吞吐尚未实测，不做数值承诺。

五、投入与产出

指标	数值	说明
整机投入	**3.0 万元**	含安装调试、培训、3 个月技术支持
单床成本	**120 元 / 床**	3.0 万元 ÷ 250 床
年电费	约 0.2 万元	**按满载 60%、0.8 元/度估算**（电价为假设值）

工时节约（理论估算）：按 250 张床位、每人每天 1 份文书由 AI 生成初稿、**假设每份节约 10 分钟**计算，每天约 42 小时，相当于 5 名医生各 8 小时。

> **这是理论上限**："每份节约 10 分钟"为假设值，未做临床计时统计。实际节约取决于采用率与医生复核方式，需在试用期实测。

六、落地路径（建议分三步）

第一步：试用（本期投入 3.0 万元）

采购 1 台服务器，部署在院内网机房，选择 1–2 个科室试用 3 个月。

试用期验收指标（用于判断是否值得推广）：

指标	要求
系统可正常加载模型	是
端到端生成速度	≥95 token/秒
每天可生成的文书数	≥680 份
连续运行 72 小时无故障	是
医生对文书质量的认可度	≥3.5 / 5 分

> 第 2、3 项为验收判据，不是当前承诺值；第 4 项"72 小时"需在试用期内验证，本机尚未做长时连续运行测试。

第二步：按需扩容（视试用结果）

现状床位	加什么	追加投入	效果
250 → 500 床	加 1 台同配置服务器	2.7 万元	处理更多的临床 AI 需求
500 → 750 床	再加 1 台	2.7 万元	处理更多的临床 AI 需求
需要不间断服务	加 1 台备用机	2.7 万元	主备自动切换

扩容不需要停机和换机——新服务器接入院内网即可，原有设备继续使用。

第三步：能力升级（可选，需另行验证）

如需高质量推理能力（疑难病例的逻辑推理），可选配 32 GB 显存服务器运行 DeepSeek 系列模型，与现有服务器并行工作。

> **该配置的实测状态**：Linux 环境下生成速度约 27–30 token/秒（社区实测数据）。**本地量化版本的质量评分尚未验证**，销售前会提供独立验证报告。

七、需要医院配合的事项

事项	说明	责任方
机房机位	1 个标准机位 + 220 V 供电（约 0.5 kW）	院方信息科

事项	说明	责任方
网络接入	院内网千兆接入（实测流量仅 3 KB/s，要求很低）	院方信息科
网段确认	确认服务器所在网段无外网出口（满足"数据不出院"）	院方信息科
医生复核流程	明确 AI 初稿由谁复核、如何签字	医务科
系统集成	与现有 HIS/EMR 对接取数	我方实施

注意：AI 服务器接入的网段若存在外网出口，需在交换机上做一次访问限制（一次性配置，无采购成本）。

八、结论与建议

建议采用"先试后用"的三步走策略：

1. **本期**：投入 3.0 万元，采购 1 台服务器，选 1–2 个科室试用 3 个月
2. **验证**：以试用期 5 项指标为依据，判断是否值得推广
3. **决策**：达标则按床位扩容，不达标则终止，损失控制在 3.0 万元以内

这个方案的价值不在于技术先进性，而在于用最低成本验证"AI 辅助是否真的能减轻医生负担"。

附：数据来源与承诺边界

项	数据性质	来源
端到端速度 102.9 token/秒	**实测**	本机 6 份真实病例，同一脚本
速度范围 95.0–112.2	**实测**	同上
显存命中率 77%	**实测**	引擎运行指标
显存 12→32 GB 仅提升 2.9%	**实测**	同批病例对照测试
单份诊断分析 14,130 token	**实测**	本机 5 例均值
每日产能 8.15 M token	**折算**	实测速度 × 22 小时
覆盖 250 床	**折算**	产能 ÷ 每人 token 需求
年电费 0.2 万元	**假设**	满载 60%、电价 0.8 元/度
工时节约 42 小时	**假设**	每份节约 10 分钟（未做临床计时）
8 路并发下的吞吐	**未验证**	引擎支持 8 路，但未测并发总吞吐
72 小时连续运行	**未验证**	本机未做长时测试
DeepSeek 质量评分	**未验证**	官方云端 4.47，本地量化版未测

承诺边界：本文只对"实测"栏的数据负责。"折算"栏为基于实测的推算，实际以现场压测为准。"假设"与"未验证"栏不作为合同承诺。

说明：本方案的所有性能数据均来自本地实测，不是厂商宣传值。报价为整机含安装调试、培训与 3 个月技术支持的价格；硬件价格随市场波动，实际采购以合同为准。

> **AI 生成内容为"初稿"**，须由医生复核后方可使用，系统不替代医生的诊断责任。