医院 AI 辅助系统本地部署方案

> 编制日期：2026 年 11 月 4 日（v4，RTX 5070 方案）
> 适用对象：250 张床位及以下的二级/县级医院
> 核心特点：**单院投入 3.0 万元，数据不出医院，可先试后用**

一、方案概览

本方案用一台服务器的预算，为医院部署一套**完全本地运行**的 AI 辅助系统，覆盖诊断分析、诊疗计划、病历文书三大场景。

项目	内容
部署位置	医院内网机房（数据不出院）
起步投入	**3.0 万元**（含安装调试）
覆盖床位	**约 250 张**
起步形态	1 台服务器，可先试用 3 个月
扩展方式	按需加服务器，不换整机、不停机

与"云服务"的根本区别：所有病历数据、AI 推理都在院内完成，不经过任何外部网络。

二、配置清单

单卡服务器（整机报价 3.0 万元，含安装调试）

项目	规格
计算卡	NVIDIA RTX 5070 12 GB
处理器	Intel Core i5-12400（6 核 12 线程）
主板	B660
内存	**64 GB DDR5**
电源	650 W 金牌
存储	2 TB 固态
散热 / 机箱	风冷 / 中塔
交付内容	硬件、系统安装、模型部署、使用培训、3 个月技术支持

能力：8 路并发，**约 250 张床位**的日常 AI 文书需求。

> **为什么选 12 GB 显存就够**：AI 模型约 62 GB，12 GB 显存缓存其中最常访问的部分（命中率约 77%），其余从 64 GB 内存读取。**实测表明，把显存加大到 32 GB，速度只提升约 3%**——边际收益很低，不必为此多付近一倍的价格。

> **为什么内存要 64 GB**：模型约 62 GB，显存装不下的部分需常驻内存。32 GB 内存无法运行。

> **为什么选 RTX 5070**：采用与主流 AI 服务器同代的 NVIDIA 架构，支持 CUDA 生态，驱动成熟、兼容性好。已完成连续运行与真实病例验证。

三、系统能做什么

项目	数值
每天可处理的住院患者	**约 250 人**
每天可生成的文书数	**约 760 份**
同时并发路数	**8 路**
单份文书耗时	2–5 分钟（取决输出长度）
适用床位	250 张以内

通俗理解：一晚上能把全院 250 名住院患者的文书各跑一遍；医生 08:00 上班时，全部结果已就绪。

使用方式：白天医生点击即用（8 路并发）；夜间系统自动批量生成，次日上班前完成。

覆盖范围：诊断分析、诊疗计划、病情小结、入院记录、首次病程记录、查房记录。

> **关于单份耗时的说明**：同一份文书两次生成，耗时可差 2 倍以上——原因是模型内部推理过程的长短由采样随机性决定，与硬件性能无关。做容量规划应按"token 总量"计算，不能按"份数"。

四、投入与产出

指标	数值
整机投入	**3.0 万元**（含安装调试）
单床成本（按 250 床）	**120 元 / 床**
年电费（满载 60%）	约 0.2 万元

按 250 张床位计算，单床一次性投入 120 元。

工时节约（保守估算）：按 250 张床位、每人每天 1 份文书由 AI 生成初稿、每份节约 10 分钟计算，每天可节约约 **42 小时**医生工时，相当于 5 名医生各 8 小时。

> 实际节约取决于采用率——并非所有文书都会用 AI 初稿，也并非所有初稿都能直接采纳。这是"理论上限"，供决策参考。

五、落地路径（建议分三步）

第一步：试用（本期投入 3.0 万元）

采购 1 台服务器，部署在院内网机房，选择 1–2 个科室试用 3 个月。

试用期验收指标：

指标	要求
系统可正常加载模型	是
每天可生成的文书数	**≥680 份**
同时 8 路并发不卡顿	是
连续运行 72 小时无故障	是
医生对文书质量的认可度	≥3.5 / 5 分

第二步：按需扩容（视试用结果）

现状床位	加什么	追加投入	效果
250 → 500 床	加 1 台同配置服务器	2.7 万元	处理更多的临床 AI 需求
500 → 750 床	再加 1 台	2.7 万元	处理更多的临床 AI 需求
需要不间断服务	加 1 台备用机	2.7 万元	主备自动切换

扩容不需要停机和换机——新服务器接入院内网即可，原有设备继续使用。

第三步：能力升级（视业务需要）

如需高质量推理模块（疑难病例的逻辑推理），可另配一台 32 GB 显存的专业卡服务器运行 DeepSeek 系列模型，与现有服务器并行工作。

升级项	说明	投入
高质量推理服务器	32 GB 专业卡 + Linux + DeepSeek 模型，每天约 170 份高质量推理	约 3.5 万元（新增 1 台）

六、需要医院配合的事项

事项	说明	责任方
机房机位	1 个标准机位 + 220 V 供电（约 0.5 kW）	院方信息科
网络接入	院内网千兆接入（实测流量仅 3 KB/s，要求很低）	院方信息科
网段确认	确认服务器所在网段无外网出口（满足"数据不出院"）	院方信息科
医生复核流程	明确 AI 初稿由谁复核、如何签字	医务科
系统集成	与现有 HIS/EMR 对接取数	我方实施

注意：AI 服务器接入的网段若存在外网出口，需在交换机上做一次访问限制（一次性配置，无采购成本）。

七、结论与建议

建议采用"先试后用"的三步走策略：

1. **本期**：投入 3.0 万元，采购 1 台服务器，选 1–2 个科室试用 3 个月
2. **验证**：以试用期 5 项指标为依据，判断是否值得推广

3. **决策**：达标则按床位扩容，不达标则终止，损失控制在 3.0 万元以内

这个方案的价值不在于技术先进性，而在于用最低成本验证"AI 辅助是否真的能减轻医生负担"。 验证成功再追加投入，比一次性采购数十万元的风险小得多。

附：技术参数与测量口径

项	数值	来源
模型	Qwen3.8-Flash-Next 125B/6B MoE Q2_0	—
模型体积	约 62 GB（磁盘）	本地文件
生成速度	**102.9 token/秒（均值）**	**本机 6 份真实文书实测**
速度范围	95.0–112.2 token/秒	同上
每份诊断分析 token	14,130	本机 5 例实测均值
每日产能	8.15 M token	102.9 × 22 小时
显存缓存	约 4.8 GB（命中率约 77%）	引擎指标

> **测量口径（重要）**：以上速度均为**端到端**（从提交到完成，含输入预处理），不是引擎内部的解码速度。后者通常比端到端高 15–30%，不能用于对外承诺。

> **说明一**：本方案的所有性能数据均来自**本地实测**，不是厂商宣传值或外推估算。同一批病例、同一脚本、同一口径。

> **说明二**：本文报价为整机含安装调试、培训与 3 个月技术支持的价格。硬件价格随市场波动，实际采购以合同为准。

> **说明三**：AI 生成内容为"初稿"，须由医生复核后方可使用，系统不替代医生的诊断责任。