医院 AI 辅助系统本地部署方案（推广版）

编制日期：2026 年 11 月 4 日（v2，按实测修订）
适用对象：600 张床位及以下的二级/县级医院
核心特点：**单院投入 2.45 万元起，数据不出医院，可先试后用**

一、方案概览

本方案用两台普通服务器的预算，为医院部署一套**完全本地运行**的 AI 辅助系统，覆盖诊断分析、诊疗计划、病历文书三大场景。

项目	内容
部署位置	医院内网机房（数据不出院）
起步投入	**2.45 万元**（一台双显卡服务器）
覆盖床位	**约 550 张**
起步形态	1 台服务器，可先试用 3 个月
扩展方式	按需加服务器，不换整机、不停机

与"云服务"的根本区别：所有病历数据、AI 推理都在院内完成，不经过任何外部网络。

二、配置清单

推荐起步：双显卡服务器（2.45 万元）

项目	规格	价格
计算卡 ×2	AMD RX 7900 XTX 24 GB	13,576 元（6,788 × 2）
显存合计	**48 GB**	—
处理器	Intel i7-14700KF（20 核 28 线程）	2,300 元
主板	Z790M（双显卡 x8/x8）	1,400 元
内存	**96 GB DDR5**（3 × 32 GB）	4,497 元
电源	1000 W 金牌	1,200 元
机箱 / 硬盘 / 散热	中塔 / 2 TB 固态	1,500 元
整机合计		**约 24,500 元**

能力：8 路并发，**约 550 张床位**的日常 AI 文书需求。

为什么选 48 GB 显存：本系统使用的 AI 模型约 35 GB。48 GB 显存可以**完整装载**，不需要从内存临时调取权重——这是速度的关键。32 GB 的卡只能装 59%，速度会掉一半。

> **为什么内存要 96 GB**：模型运行需要把完整权重放在内存中备用，两套副本约需 54 GB，加系统占用约 70 GB。64 GB 会不够。

可选：高质量推理服务器（3.24 万元）

用于**疑难病例、诊断逻辑推理、诊疗计划逻辑推理**等对质量要求高的场景。

项目	规格	价格
计算卡	AMD R9700 32 GB 专业卡	16,099 元
处理器	AMD Ryzen 9 9950X（16 核）	4,500 元
主板	X870E 工作站主板	3,000 元
内存	64 GB DDR5	6,000 元
电源	850 W 金牌（专业卡原生供电）	900 元
机箱 / 硬盘 / 散热	中塔 / 2 TB 固态 / 风冷	1,900 元
整机合计		**32,399 元**

能力：每天约 **170 份**高质量推理（一份约 8 分钟）。

> 该配置运行 DeepSeek V4.1 模型（与官方云端同系列），质量明显高于批量层模型。实测评分：诊疗计划 **4.47 vs 3.75**、诊断分析 **4.18 vs 3.56**（满分 5）。
> 注意：以上评分为官方云端模型成绩，本地量化版本的质量尚待验证。

三、系统能做什么

项目	起步版（双卡）	高质量版（R9700）
每天可处理的住院患者	**约 550 人**	约 170 人（仅高质量场景）
每天可生成的文书数	**约 1,650 份**	约 170 份
同时并发路数	**8 路**	8 路
单份文书耗时	3–5 分钟	约 8 分钟
适用床位	600 张以内	疑难病例专用

通俗理解：起步版相当于"一晚上能把全院 550 名住院患者的文书各跑一遍"；高质量版相当于"每天能精算 170 份疑难病例"。

使用方式：白天医生点击即用（8 路并发）；夜间系统自动批量生成，次日上班前完成。医生 08:00 上班时，全部结果已就绪。

四、投入与产出

指标	起步版	高质量版	两套并用
整机投入	2.45 万元	3.24 万元	5.69 万元

指标	起步版	高质量版	两套并用
覆盖床位	590 张	疑难专项	590 张 + 疑难
单床成本	**45 元 / 床**	—	—
年电费（满载 60%）	约 0.4 万元	约 0.25 万元	约 0.65 万元

按 550 张床位计算，单床一次性投入 45 元。

工时节约（保守估算）：按 550 张床位、每人每天 1 份文书由 AI 生成初稿、每份节约 10 分钟计算，每天可节约约 **92 小时**医生工时，相当于 11 名医生各 8 小时。

> 实际节约取决于采用率——并非所有文书都会用 AI 初稿，也并非所有初稿都能直接采纳。这是"理论上限"，供决策参考。

五、落地路径（建议分三步）

第一步：试用（本期投入 2.45 万元）

采购 1 台双显卡服务器，部署在院内网机房，选择 1–2 个科室试用 3 个月。

试用期验收指标：

指标	要求
系统可正常加载模型	是
每天可生成的文书数	**≥1,500 份**
同时 8 路并发不卡顿	是
连续运行 72 小时无故障	是
医生对文书质量的认可度	≥3.5 / 5 分

第二步：按需扩容（视试用结果）

现状床位	加什么	追加投入	效果
550 → 1,100 床	加 1 台同配置服务器	2.45 万元	处理更多的临床 AI 需求
1,100 → 1,650 床	再加 1 台	2.45 万元	处理更多的临床 AI 需求
需要高质量推理	加 1 台 R9700 服务器	3.24 万元	疑难病例精算

扩容不需要停机和换机——新服务器接入院内网即可，原有设备继续使用。

第三步：容灾兜底（经费宽松时）

增加 1 台同配置备用机，主服务器故障时自动接管。

六、需要医院配合的事项

事项	说明	责任方
机房机位	1 个标准机位 + 220 V 供电（**约 1.1 kW**）	院方信息科
网络接入	院内网千兆接入（实测流量仅 3 KB/s，要求很低）	院方信息科
网段确认	确认服务器所在网段无外网出口（满足"数据不出院"）	院方信息科
医生复核流程	明确 AI 初稿由谁复核、如何签字	医务科
系统集成	与现有 HIS/EMR 对接取数	我方实施

注意：AI 服务器接入的网段若存在外网出口，需在交换机上做一次访问限制（一次性配置，无采购成本）。

七、结论与建议

建议采用"先试后用"的三步走策略：

1. **本期**：投入 2.45 万元，采购 1 台双显卡服务器，选 1–2 个科室试用 3 个月
2. **验证**：以试用期 5 项指标为依据，判断是否值得推广
3. **决策**：达标则按床位扩容，不达标则终止，损失控制在 2.45 万元以内

这个方案的价值不在于技术先进性，而在于用最低成本验证"AI 辅助是否真的能减轻医生负担"。 验证成功再追加投入，比一次性采购数十万元的风险小得多。

附：关键技术参数与数据来源

项	数值	来源
模型规模	约 35 GB	本机模型文件实测
单卡 7900 XTX 单流速度	117 tok/s	社区 Linux 实测（同款模型）
双卡聚合速度	约 234 tok/s	单卡 × 2（本系统按卡独立部署）
显存需求	48 GB 可完整装载	模型 35 GB + 缓存
内存需求	96 GB	两套副本 54 GB + 系统
单份诊断分析 token	14,130	本机 5 例实测均值

说明一：7900 XTX 的速度数据来自社区在 Linux 下的实测（同款模型、同款量化）。本系统将部署在 Windows 上，**Windows 下的 gfx11（RDNA3）性能官方尚未验证**，实测值可能低于 117 tok/s。建议先采购 1 张卡验证，达到 110 tok/s 以上再采购第二张。

说明二：本文所有价格基于 2026 年 11 月市场行情，实际采购以询价为准。显卡价格波动较大，建议合同锁定单价与供货期。

说明三：高质量版的 DeepSeek V4.1 模型仅在 Linux 下可用，Windows 下速度会下降约 70%，因此该配置需单独部署 Linux 系统。